

# 一种轻量化 YOLOv4 输电线路防外力隐患检测方法

周鹏杰<sup>1</sup>, 赵泽宇<sup>2</sup>, 袁斌<sup>1</sup>, 董卓元<sup>1</sup>, 高永亮<sup>1</sup>, 姚新宇<sup>1</sup>, 张军强<sup>1</sup>, 李晋<sup>1</sup>

(1. 国网陕西省电力有限公司经济技术研究院, 陕西 西安 710075)

(2. 西安交通大学计算机学院, 陕西 西安 710049)

**摘 要:** 输电线路地处多野外偏远, 易受各种外力隐患破坏而出现安全故障。针对基于深度学习的输电线路外力隐患检测模型不能满足边缘部署的实时性需求的问题, 本文提出一种轻量化 YOLOv4 的输电线路防外力隐患检测方法。首先引入深度可分离卷积, 采用 MobileNetv3 作为 YOLOv4 模型的主干网络用以提取输电线路图像的多尺度特征。然后用所建立的输电线路图像数据集对所改进的轻量化模型进行训练、验证和测试。实验结果表明, 本文方法在输电线路外力隐患检测中准确率可达到 87.73%, 运算速度可达到 FPS 为 32.49, 与同类方法相比, 本文方法综合性能较优。

**关键词:** 输电线路; 外力隐患; 深度学习; 轻量化; 边缘部署

中图分类号: TM763

## An Transmission Line External Hidden Damage Detection Method Based on Light-weighted YOLOv4

Zhou Pengjie<sup>1</sup>, Zhao Zeyu<sup>2</sup>, Yuan Bin<sup>1</sup>, Dong Zhuoyuan<sup>1</sup>, Gao Yongliang<sup>1</sup>, Yao Xinyu<sup>1</sup>, Zhang Junqiang<sup>1</sup>, Li Jin<sup>1</sup>

( 1. Economic and Technical Research Institute, State Grid Shanxi Electric Power Co., Ltd., Xian 710075, Shanxi, China

2. School of Computer Science, Xi'an Jiaotong University, Xian 710049, Shanxi, China )

**Abstract:** Transmission lines are located in many remote areas and are prone to safety damage caused by various external forces. To resolve the problem that the current deep learning models which aim to detect external damage along the transmission lines cannot meet the real-time requirements of edge deployment, this paper proposes a detection method based on lightweight YOLOv4 model. Firstly, deep separable convolution is introduced, and MobileNetv3 is used as the backbone network of YOLOv4 to extract multi-scale features of the transmission line images.

The improved lightweight model is trained, validated, and tested using the established transmission line image datasets. The experimental results show that the accuracy rate of the proposed method in this paper can reach 87.73% , and the calculation speed can reach 32.49 in FPS. Compared to other methods, this method has better trade-off.

**Key words:** transmission lines; external damage; deep learning; lightweight; edge deployment

## 0 引言

随着我国建立的输电线路电压等级不断升高, 输电线路经常跨越多个省份, 离主干道路遥远, 其安全运行环境比较复杂恶劣, 自然灾害、恶劣天气和人为的外力破坏往往导致各种安全故障发生。据统计, 约 30% 的输电线路安全故障是由人为的外力破坏如塔吊、吊车或其他大型的施工机械所致<sup>[1]</sup>。人为的外力破坏已经成为除了自然灾害、恶劣气候之外的威胁输电线路安全运行的最大隐患。因此, 输电线路作为电网安全运行的重要组成, 如何对其安全运行进行实时监控以预警各种外力破坏行为的发生就显得尤为必要。

近年来, 随着现代信息技术的发展, 在线巡检方式如视频拍照、直升机航拍等受到广泛关注。上述在线巡检方式与传统人工巡检方式相比, 虽然提高了工作效率, 但是需要将采集的图像或视频数据回传到监控系统平台, 通过人工筛选或服务端数据分析以识别外力破坏目标, 存在容易出现漏判或误判、无法实时预警等问题。

随着人工智能的发展, 基于深度学习进行目标检测为输电线路外力破坏的检测提供了新方法。张煜彬等<sup>[1]</sup>根据输电线路

主要的外力危险行为的特征, 基于改进优化的 YOLOv3 网络模型实现了对人、吊车、挖掘机和其他工程车的识别。孙翠英等<sup>[2]</sup>引入 I-OHEM 算法 YOLOv3 网络结构进行优化改进, 以实现输电线路通道内的吊臂、工程车辆和活动人员的检测。魏贤哲等<sup>[3]</sup>对 MaskR-CNN 模型进行改进以实现挖掘机、吊车、塔吊、泵车、山火、异物悬挂这六种常见外力破坏目标的检测。田二胜等<sup>[4]</sup>首先改进 K-means 算法对图片样本集目标的大小进行聚类分析, 然后基于 YOLOv4 模型以提高有雾天气下施工机械识别的准确率。然而, 以上大多数卷积神经网络模型均使用标准卷积, 模型计算时间长, 不能满足输电线路图像外破目标检测模型边缘部署实时性的应用需求。

近几年, 随着深度学习技术的发展, 越来越多的有关深度学习的研究工作表明, 通过改变卷积方式如引入深度可分离卷积<sup>[5]</sup>或组卷积<sup>[6]</sup>以优化卷积模块, 减少卷积计算, 或通过减少标准卷积核权重或卷积输出通道数<sup>[7]</sup>, 可以减少冗余的网络参数, 提高计算效率<sup>[8]</sup>。如文献<sup>[9]</sup>对 YOLOv4 进行轻量化改进以实现对口罩的检测。文献<sup>[10]</sup>引入深度可分离卷积, 基于 YOLOv4 模型实现了输电线路鸟巢的检测和识别。

文献[8]搭建 MobileNetv2-YOLOv4 轻量化网络模型实现了对船只的检测。

深度可分离卷积通过将标准卷积拆分为深度卷积和点卷积，大大减少运算量和模型参数量，但基于深度可分离卷积的网络模型在精度上却有一定降低。相比以前版本，MobileNetv3<sup>[3]</sup>通过引入轻量级注意力模块（Squeeze and Excitation，SE），提高了模型精度，同时没有增加运算量。另外综合考虑推理速度和检测性能，YOLOv4<sup>[11]</sup>依然是最佳对象检测框架，且可定制化程度很高。

因此，本文提出结合 MobileNetv3 和基于 YOLOv4 一阶检测器的输电线路防外力破坏轻量化检测方法。首先对 YOLOv4 网络模型进行轻量化改进，并基于输电线路场景下图像数据集，使用迁移学习技术对改进的网络模型进行训练、验证和性能测试，实验仿真结果表明了本文所研究方法的有效性。

## 1 轻量化 YOLOv4 网络搭建

### 1.1 YOLOv4 基础框架

YOLOv4 作为目前比较理想的一阶目标检测器，网络结构主要包括主干网络、特征增强 Neck 模块和 YOLO-Head。其中主干网络采用 CSPDarknet53<sup>[12]</sup>，用以提取多尺度特征；特征增强 Neck 模块包括 PANet<sup>[13]</sup>和 SPP<sup>[14]</sup>，PANet 通过构建自下而上的特征金字塔和自上而下的上采样路径，可以有效融合多尺度特征。SPP 通过不同规格的分割方式对输入特征图进行处理，增加感受野，提高模型的检测精度。YOLO-Head 对所输入的特征进行分类和回归预测。

### 1.2 MobileNetv3

MobileNetv3 由多个 Bneck 结构组成，使用  $3 \times 3$  标准卷积提取特征和  $1 \times 1$  卷积替代全连接层，通过最大池化操作，最终实现分类和回归预测。Bneck 结构使用深度可分离卷积以减少模型参数量，降低运算量，并采用倒置残差和线性瓶颈，将特征映射为低维表示。采用轻量级注意力 SE 模块在没有增加任何运算量的情况下提升了模型检测性能，激活函数使用 h\_swish 函数代替 swish 以降低运算量。Bneck 具体结构如图 1 所示。

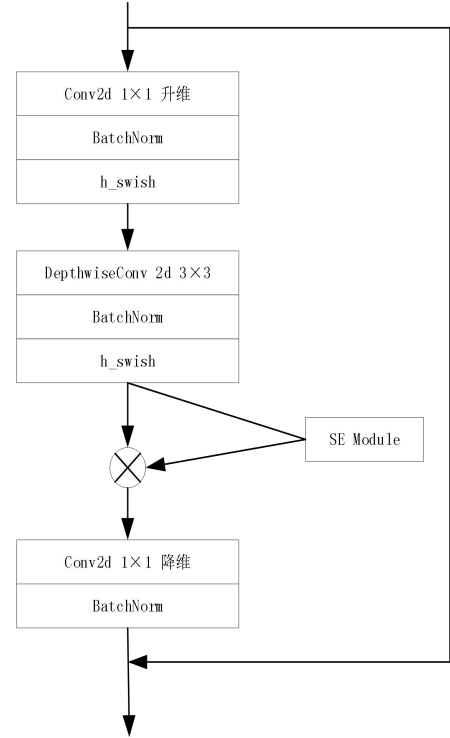


图 1 Bneck 结构图

### 1.3 YOLOv4 网络轻量化改进

原 YOLOv4 网络模型中，主干网络 CSPDarknet53 虽然特征提取性能较强，也是轻量化的残差结构，但卷积层数较多，模型理论参数量较大，运算开销比较大，不太适合输电线路场景下外力隐患检测模型的边缘部署。本文研究采用更加轻量化

的卷积神经网络 MobileNetv3 作为 YOLOv4 网络模型中的主干网络用以多尺度特征提取。

考虑到实际的外破隐患目标的尺度变化,保留 PANet 作为模型的特征融合模块,以实现有效地融合多尺度特征。PANet 从底层到高层构建一个特征金字塔,通过多个不同大小的卷积核,对输入图像进行卷积和下采样,生成多个不同尺度的特征图。这些特征图包含了不同尺度下的输电线路外破信息,可以更好地处理不同大小的目标物体。轻量化改进后的网络结构如图 2 所示。

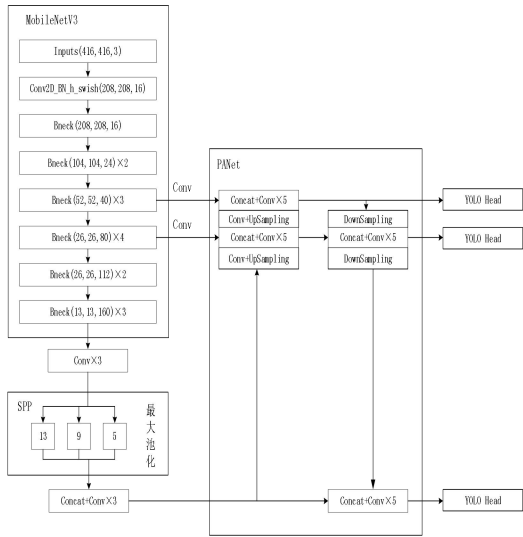


图 2 轻量化 MobileNetV3-YOLOv4 结构图

## 2 实验仿真

### 2.1 建立输电线路图像数据集

将监控摄像机安装在输电线路杆塔上,用以采集输电线路场景图像,对所采集的图像进行筛选,加上部分网络下载图像共收集样本图像 1361 张,其中外破类型包括塔吊、吊车、其他施工机械等。考虑输电线路场景多多偏远野外,易受各种干扰,采用数字图像增强技术如去噪、亮度增强、

几何变换等对图像进行增强。原 1361 张样本图像数据集经过图像增强后扩充到 4083 张,并将扩充后的数据集按照 6:2:2 的比例划分为训练集、验证集和测试集。划分结果如表 1 所示。

表 1 数据集划分情况表

类别	训练集	验证集	测试集	合计
施工	1201	400	400	2001
机械				
塔吊	1333	445	445	2223
吊车	1070	357	357	1784

### 2.2 实验环境和参数设置

本文采用 Windows 10 操作系统,GPU 硬件选择 NVIDIA GeForce RTX 3090,软件为 CUDA11.1, CUDNN8.05。开发语言为 Python 3.7,搭建基于 Pytorch1.7.1 框架的模型训练及测试环境,采用本文算法模型对输电线路外破隐患目标进行识别,输出被检测图片中外破隐患目标的类别和边框。为了验证 MobileNetV3-YOLOv4 目标检测算法在输电线路防外破数据集集中的表现,修改预训练模型的配置文件相关参数,以适用于本项目特点,部分超参数值如表 2 所示。

表 2 超参数设置情况

名称	参数
批次大小	24
训练轮次	500
学习率	0.001

本文选择 Adam (Adaptive momentum) 作为网络的优化器,Adam 取代了传统的随机梯度下降,该方法能够根据训练数据不断地更新神经网络的权重,在深度学习中常被用作最优解。其优点是:运算效率高,占用内存少和梯度对角缩放的不变性,适于求解含有大量参数和大量数据的最优问题;适合于处理含有较高噪音或稀疏梯

度的问题；只需要很小的调参，且超参数便于解释。本次实验用到优化器参数 momentum 设置为 0.937，为防止过拟合，weight-decay（权重衰减）设置为 0，后在训练的过程中根据 Loss 损失值大小进行动态调整模型训练损失下降如图 3 所示。最终的训练集损失达到 0.032，验证损失达到 0.030，说明网络收敛良好。




图 3 模型训练损失曲线

### 2.3 评价指标

将网络模型预测类别结果与真实标签结果进行比较，若预测结果和真实结果一致为真，预测和实际不一致为假。一般用真正例（True Positive, TP）、假正例（False Positive, FP）、真反例（True Negative, TN）和假反例（False Negative, FN）四个指标，来判决网络模型的预测性能。

精准率(Precision)表示预测结果为正例样本中真实为正例的比例。精确率高，意味着分类器要尽量在“更有把握”的情况下才将样本预测为正样本。如式(1)为精准率公式：

$$Precision = \frac{TP}{TP+FP} \quad (1)$$

平均精度均值(mAP)通过对所有类别的 AP 取平均来计算，更全面地反映了模型的检测性能，mAP 如式(2)所示。

$$mAP = \frac{\sum_{i=1}^N AP_i}{N} \quad (2)$$

其中， $N$  表示分类的类别个数， $AP_i$  表示第  $i$  个类别的平均精度值。

### 2.4 实验结果及分析

通过上一节的分析，用模型的精确率、平均精度均值作为评估模型识别效果的指标，以每秒传输帧数作为评估算法速度的指标。计算得到塔吊、吊车、其他施工机械精准率如图 4 所示。评估的平均精度均值 mAP 如图 5 所示。




图 4 识别精准率曲线

为了验证本文提出的模型的可行性和鲁棒性，我们在不同场景下选择了多组图像样本，并对模型进行了性能测试。这些样本包含了不同的背景、姿态、光照和多目标情况。我们的实验结果如图 6 所示。从图中可以看出，我们的模型具有较强的

鲁棒性，能够准确地识别不同光照强度下拍摄的目标图片，并且能够适应图片的色彩和亮度变化。这表明我们的模型具有更广泛的适用性和更强的实用价值。

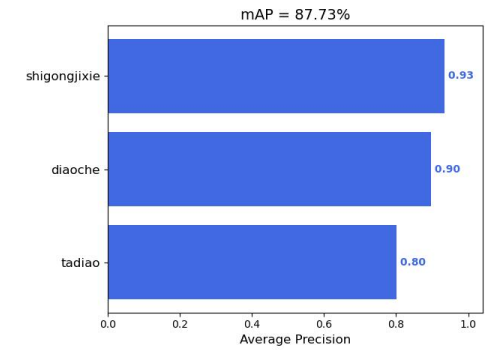


图5 MobileNetV3-YOLOv4 mAP 评估



图6 模型预测结果图

为了进一步验证了本文所提方法的有效性，文章对比了本文方法与 YOLOv4 和 Faster R-CNN 两种目标检测算法在我们的数据集上的表现，结果如表 3 所示。

表3 不同模型对比结果

模型	参数量 /MB	FPS	mAP/%
YOLOv4	245.0	24.48	89.15
Faster R-CNN	521.6	14	83.33
<b>本文方法</b>	<b>44.74</b>	<b>32.49</b>	<b>87.73</b>

从表 3 可以看出，本文算法在模型大小、FPS(帧率)和 mAP(平均精度均值)三个方面都有优势，模型大小仅为 YOLOv4 的 1/5，而平均精度可以达到 87.73%，检测

速度较 YOLOv4 提升了约 33%；在平均精度高于二阶段网络模型 Faster R-CNN 的情况下，本文模型大小较其降低了约 91%，检测速度提升了约 132%

综合来看，本文算法在输电线路隐患目标检测任务中表现优异，主要原因是我们采用了轻量化的网络结构和优化的训练策略。本文算法中使用的卷积核大小和深度都相对较小，可以减少参数量和计算量。此外，我们使用了多尺度训练和数据增强等策略，提高了模型的泛化能力和稳定性。

### 3 总结

本文提出了一种轻量化 YOLOv4 输电线路外力隐患检测方法。通过引入深度可分离卷积对 YOLOv4 基础模型进行了轻量化改进，以减少模型的理论参数量，降低运算量，以适配输电线路防外力隐患模型的边缘部署需要。通过实际采集输电线路场景图像和网络下载方式收集并建立了图像数据集，并采用该数据集对所提出的轻量化模型进行了训练、验证和测试。实验结果表明，本文方法对塔吊、吊车、施工机械等检测精度可达到 87.73%，并实现了 FPS 约 33 的实时性，证明了本文方法的有效性，为输电线路防外力破坏的智能化和边缘部署提供了理论指导和实践借鉴意义。由于输电线路实际场景中，可能存在多种外力隐患，如飞鸟、导线异物、导线、烟火、火焰等，未来工作通过输电线路塔杆监控摄像机采集更多的样本图像并扩充数据集，研究并优化样本图像不平衡下网络模型的性能，以提高网络模型的检测精度和泛化能力。

参考文献：

- [1] 张煜彬, 方中纯. 基于改进 YOLOv3 的输电线路外力破坏危险行为检测[J]. 内蒙古科技大学学报, 2021, 040(004):364-369.
- [2] 孙翠英, 蔡文彪, 贾伯岩,等. 基于 I-OHEM 的输电线路防外破目标检测方法研究 [J]. 电气自动化, 2020, 42(4):4.
- [3] 魏贤哲, 卢武, 赵文彬,等. 基于改进 Mask R-CNN 的输电线路防外破目标检测方法研究[J]. 电力系统保护与控制, 2021, 49(23): 155-162.
- [4] 田二胜, 李春蕾, 朱国栋,等. 基于 YOLOv4 的输电线路外破隐患识别算法[J]. 计算机系统应用, 2021, 30(7):7.
- [5] Howard A, Sandler M, Chen B, et al. Searching for MobileNetV3[C]. 2019 IEEE/CVF International Conference on Computer Vision (ICCV). IEEE, 2020.
- [6] Zhang X, Zhou X, Lin M, et al. ShuffleNet: An Extremely Efficient Convolutional Neural Network for Mobile Devices[J]. 2017.
- [7] Park S J, Lim C G, Ahn C. Network Slimming for Compressed : Ensing Cardiac Cine MRI[J]. Electronics Letters, 2021.
- [8] Yue T, Yang Y, Niu J M. A Light-weight Ship Detection and Recognition Method Based on YOLOv4[C]. 2021 4th International Conference on AEMCSE. 2021.
- [9] 叶子勋, 张红英. YOLOv4 口罩检测算法的轻量化改进[J]. 计算机工程与应用, 2021, 57(17):12.
- [10] 王杨杨, 曹晖, 莫文昊. 基于深度学习的改进型 YOLOv4 输电线路鸟巢检测与识别[J]. 智慧电力, 2023, 51(1):7.
- [11] Bochkovskiy A, Wang C Y, Liao H. YOLOv4: Optimal Speed and Accuracy of Object Detection[J]. 2020.
- [12] Wang C Y, Liao H, Wu Y H, et al. CSPNet: A New Backbone that can Enhances Learning Capability of CNN[C]. 2020 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). IEEE, 2020.
- [13] Liu S, Qi L, Qin H, et al. Path Aggregation Network for Instance Segmentation[J]. IEEE, 2018.
- [14] He K, Zhang X, Ren S, et al. Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition[C]. IEEE Transactions on Pattern Analysis & Machine Intelligence. 2014:1904-16