

一种改进型 YOLOv4 输电线路防外破检测方法

董卓元¹, 高永亮¹, 袁斌¹, 姚新宇¹, 张军强¹, 曾健¹, 赵泽宇², 周鹏杰¹

(1. 国网陕西省电力有限公司经济技术研究院, 陕西 西安 710075

2. 西安交通大学计算机学院, 陕西 西安 710049)

External Damage Detection Method of Transmission Line

Based on Improved YOLOv4

Dong Zhuoyuan¹, Gao Yongliang¹, Yuan Bin¹, Yao Xinyu¹, Zhang Junqiang¹, Zeng Jian¹, Zhao Zeyu², Zhou Pengjie¹

(1. Economic and Technical Research Institute, State Grid Shanxi Electric Power Co., Ltd., Xian 710075, Shanxi, China

2. School of Computer Science, Xi'an Jiaotong University, Xian 710049, Shanxi, China)

ABSTRACT: The images in the transmission line scenes are susceptible to various interference from the countryside environments. The current deep learning network models which aim to detect the external crack objects around the transmission line are difficult to meet both the real-time and accuracy requirements for edge deployment. Therefore, this paper proposes a method for detecting the external damage to the transmission lines, which combines the residual learning with YOLOv4 network model. Firstly, data enhancement technology is used to enhance the datasets of the collected transmission lines image, and the transmission lines image datasets for preventing external force damage is established. Secondly, considering that the external crack detection network models are easy to be deployed for the actual edge equipment, the YOLOv4 network structure has been improved which the feature extraction backbone network is built based on ResNet50. Finally, the label smoothing technique is introduced to optimize the classification loss function of YOLOv4 to alleviate the overfitting problem and improve detection accuracy of the network model. Experimental results show that the proposed method outperforms other methods in terms of computational speed and detection accuracy.

KEY WORDS: transmission line; external damage detection; deep learning; residual block; classification loss function

摘要: 输电线路场景图像易受野外多种环境干扰, 当前主流的深度学习网络模型难于满足输电线路防外破检测模型的边缘部署实时性和精度要求。本文提出了一种融合残差学习的 YOLOv4 输电线路防外破检测方法。首先采用数据增强技术对所采集的输电线路图像数据集增强, 建立了输电线路防外力破坏的图像数据集。其次, 考虑到输电线路网络模型便于实际边缘部署配置的需要, 对 YOLOv4 网络结构进行了改进, 基于 ResNet50 构建特征提取主干网络。最后引入标签平滑技术对 YOLOv4 的分类损失函数进行了优化以

减缓过拟合问题, 提高了网络模型的检测精度。用实际采集的输电线路图像构成的数据集进行了测试, 实验结果表明本文所提出的方法在运算速度和检测准确度上均优于其他方法。

关键词: 输电线路; 防外破检测; 深度学习; 残差结构; 分类损失函数

0.引言

随着我国城乡经济的快速发展和电网规模的不断壮大, 输电线路覆盖面越来越广, 具有线长、面广和多野外的特点, 容易遭受如施工机械、自然灾害等外力破坏, 如施工机械、超高车辆导致外力破坏可能导致输电线路的外破, 引发电力故障甚至安全事故。传统的输电线路巡视主要包括人工巡视、视频拍照和无人机航拍^[1]等。但上述三种工作方式需要工作人员对线路和设备进行主观判断, 容易出现漏判和误判, 无法做到实时发现输电线路中的隐患并及时预警。随着图像处理和计算机视觉技术的发展, 如何实现对输电线路外破目标的检测成为近年来的研究热点。

近年来, 基于深度学习的目标检测技术是一种可以实现对输电线路外破目标检测的重要方法, 通过对输电线路场景图像中外破目标如烟雾、火焰、

吊车、塔吊、施工机械、导线外挂异物等的类别判决和位置定位,来预测对输电线路的危险程度,不依赖于人工设置参数,自动化程度高,鲁棒性好。如文献[2]通过对 Faster R-CNN 进行网络结构改进,增加网络深度来增强网络对入侵高压架空输电线路监控区域的危险因素的识别能力。文献[3]根据防外破风险的图像特点对现有深度网络结构和损失函数进行了优化以实现有效识别输电线路外破隐患。文献[4]基于深度学习网络模型 YOLOv2 实现了输电线路绝缘子的在线识别与缺陷诊断。文献[5]采用 YOLOv3 网络模型,基于语义规则和语句模板相结合的方法,实现对施工人员安全帽佩戴的检测。文献[6]基于 YOLOv3 网络模型,结合优化的 I-OHEM 算法实现了对输电线路安全区域内的工程机械和导线异物等可疑危险目标的有效识别。文献[7]通过对 Mask R-CNN 进行改进优化,提高了对输电线路防外破目标检测的准确度。文献[8]采用 ResNet152 特征提取网络和 YOLOv3 目标检测网络相结合的方式,以实现了输电线路中防鸟刺部件识别与故障检测。文献[9][10]分别基于 YOLOv3 实现了输电线路外力破坏危险行为检测和小目标的识别。

以上在输电线路防外力破坏目标检测中常用的 Mask R-CNN、Faster RCNN、YOLOv2、YOLOv3 等网络模型,由于模型训练学习时间较长,难以满足输电线路场景下深度学习网络模型的边缘部署的应用需求。YOLOv4 在 YOLOv3 的基础上进行了改进,实现了网络模型的良好性能提升。在输电线路防外破目标检测方面,文献[11][12]基于 YOLOv4 网络结构实现了对输电线路外力隐患和异物的识别。文献[13]基于 YOLOv5 实现了输电线路附近大型违章车辆施工所造成的外力破坏。与 YOLOv3 和 YOLOv4 比较,虽然 YOLOv5 网络较小,推理速度较快,但检测精度却不如 YOLOv4 理想。

输电线路所在的野外场景易受各种环境干扰,这对输电线路外破目标的检测模型算法在实时性和精度两方面提出了更高的要求。作为一阶目标检测网络模型,综合评估推理速度和检测性能,YOLOv4 仍然是最佳对象检测框架,另外 YOLOv4 的可定制化程度很高,可根据输电线路场景图像的具体特点进行可定制化设计。更重要的是,由于输电线路外破目标检测不仅需要预测外破目标的类别信息,而且还需要预测外破目标的位置信息。而深度学习网络模型的浅层特征具有较丰富的位置

信息,深层特征具有较丰富的语义类别信息。特征金字塔(Feature Pyramid Networks, FPN)^[14]虽然可以将语义丰富的特征与精确的定位信息结合起来,但可能会导致信息传播路径过于冗长。残差学习^[15]通过残差块和恒等映射一方面可以降低模型的复杂度,另一方面可以起到松弛不同网络层之间的信息传播。

因此,本文提出一种改进型 YOLOv4 输电线路外破目标检测方法。首先,采用数据增强策略对输电线路图像数据集进行增强,以平衡各类别外破隐患图像样本数量;然后在通用的一阶目标检测模型 YOLOv4 框架下,考虑到 ResNet 网络及其多种优化的变体网络使用更加广泛和便于实际边缘部署配置的需要,基于 ResNet50 构建特征提取主干网络,并引入标签平滑技术优化损失函数,以进一步提高网络模型的性能。实验仿真结果表明,本文提出的输电线路外破目标检测模型在输电线路外破检测方面实时性和鲁棒性较好。

1.方法

为了实现对输电线路外力破坏隐患的检测,本文首先采用图像增强策略,通过对输电线路图像进行加噪、亮度调节和旋转等预处理以扩充输电线路防外力破坏图像数据集,并平衡各类别外力隐患图像样本数量。考虑到残差学习通过恒等映射可以松弛不同网络特征层之间的信息传播,融合残差学习,优化损失函数,建立了改进 YOLOv4 网络模型。在训练策略上,使用迁移学习技术将本文建立的改进型 YOLOv4 网络模型在 VOC 数据集^[15]上进行预训练,并采用增强后的输电线路图像数据集通过冻结预训练模型的卷积层进行粗调和解冻卷积层之后的微调,本文所提出的方法总体框架如图 1 所示。

1.1 数据处理

数据增强作为一种广泛使用的数据预处理方法,可以通过旋转、翻转、缩放、裁剪、添加噪声等方法产生新的图像数据来扩充原始图像数据集。本文使用数据增强方法扩充输电线路防外破图像数据集预处理步骤如下:

1) 采集输电线路场景图像

通过安装在输电线路杆塔上的监控摄像机采集输电线路场景图像,经过筛选剔除模糊、严重遮挡的图像,加上少量网上下下载图像,共收集了 1361 张样本图像,外力破坏隐患目标包括施工机械、塔

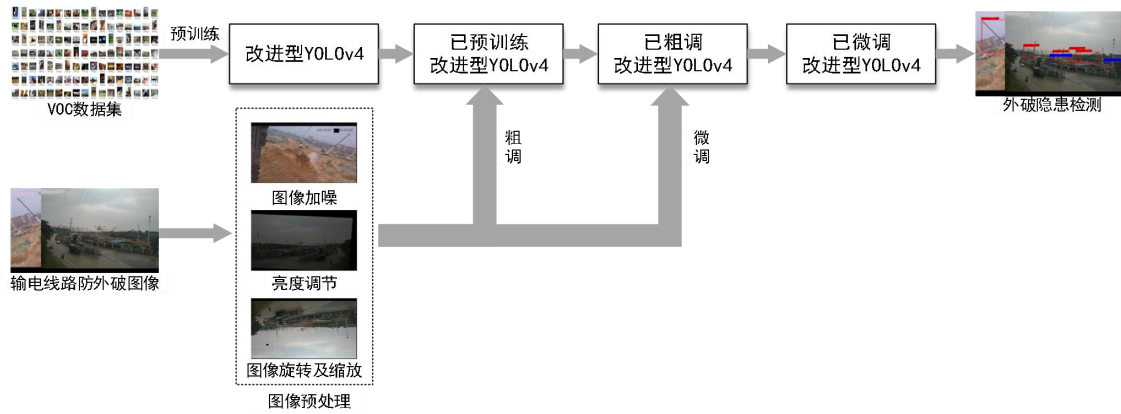


图 1 输电线路防外破检测拟议框架

Fig.1 Proposed framework for transmission line anti-breakage detection

吊、吊车等，这些外部入侵机械设施对输电线路的安全具有潜在的危害。

2) 输电线路场景图像增强

由于输电线路所在环境多偏远野外，容易受各种环境干扰，安装在输电线路杆塔上监控摄像头拍摄到的图像多存在偏暗、噪点和几何畸变等特点，本文从常用的图像数据增广方法中选取了图像加噪、亮度调节、旋转和缩放等四种图像预处理方法。针对输电线路野外场景多存在光照强度和天气变化等自然条件影响这一特点，对图像进行加噪、亮度调节可以模拟这一自然环境因素的影响，在一定程度上也可以消除自然光对图像质量的影响，同时增强了图像的多样性。针对摄像机安装角度变化、摄像机由于自然因素导致的晃动和外力隐患目标位置等因素对图像质量的影响，采用几何变换如旋转、缩放的等图像预处理方法在一定程度上可以降低这些因素的影响。增强后的图像如图 2 所示。




图 2 数据增广效果图

Fig.2 The effect of data broadening

另外由于采集的样本图像中存在施工机械、塔吊、吊车等外力破坏隐患的类别数量不平衡。类别不平衡的数据集使得深度学习网络模型对少数类别的样本特征学习不够充分，影响网络模型对外破目标的检测性能。本文采用几何变换如旋转、缩放和图像加噪等图像预处理方法对图像数据集进行增广。首先设定相应的旋转角度、缩放比例、添加噪声的类型。本文方法中将旋转角度设置为 5° ，缩放比例设置为 0.8，噪声类型选择高斯噪声。对于每个样本图像，采用数据增强方法进行处理，生成新的样本图像。然后将新样本图像加入原始样本图像数据集中。增强后的输电线路场景图像数据集样本图像数量由 1361 张增广到 4083 张，用来对输电线路外破目标检测模型进行训练学习、验证和测试。

3) 输电线路场景图像标注

采用 Labelimg 标注软件对将上述输电线路图像进行人工标注，用矩形框包络输电线路图像中外破目标，包括施工机械、塔吊、吊车的位置并标识类别标签。将上述标注之后的输电线路图像数据集按照 6:2:2 的比例随机划分为训练集、验证集和测试集。

1.2 YOLOv4 输电线路防外破检测模型结构改进

一阶目标检测器通常由三部分组成：主干网络、特征融合增强模块和目标对象预测模块^[16]。主干网络一般通过大型的图像数据集进行预训练，用以提取图像的特征，特征融合增强模块一般对提取的各个卷积层特征进行融合增强，目标对象预测模块用以实现对图像中的目标进行预测判决。YOLOv4^[16]作为一阶目标检测器，其主干网络 CSPDarkNet53^[17]提取图像特征，Neck 模块包括 SPP 结构和路径

聚合网络 PANet, 将多重感受野捕获的图像特征进行融合和增强后, 并输入到 YOLO-Head 预测模块进行回归预测。

综合考虑推理速度和网络性能, YOLOv4 虽然是比较理想的目标检测模型, 但对于输电线路场景下边缘部署的应用需求, 考虑到输电线路所在野外场景存在自然光变化、天气变化等各种自然环境干扰, 其综合性能有待进一步提升。尤其是输电线路外破目标检测不仅需要预测外力隐患的类别信息, 而且还需要预测定位外力隐患的位置信息。包含丰富位置信息的浅层特征在深度学习网络模型中的有效传播显得尤为重要。

残差网络 ResNet50^[18]及其变体使用广泛, 便于边缘部署, 另一方面残差学习通过恒等映射一方面可以降低模型的复杂度, 提高实时性, 同时起到松弛多层特征信息的有效传播, 有助于提高对输电线路外力隐患检测的性能。因此本文基于残差网络对 YOLOv4 网络结构进行改进优化, 将 YOLOv4 中的主干网络 CSPDarkNet53 替换为 ResNet50 用于多重感受野特征信息的提取和浅层特征信息的传播, 以提高对输电线路场景中外力隐患检测的实时性和鲁棒性, 满足边缘部署的应用需求。其整体结构如图 3 所示。

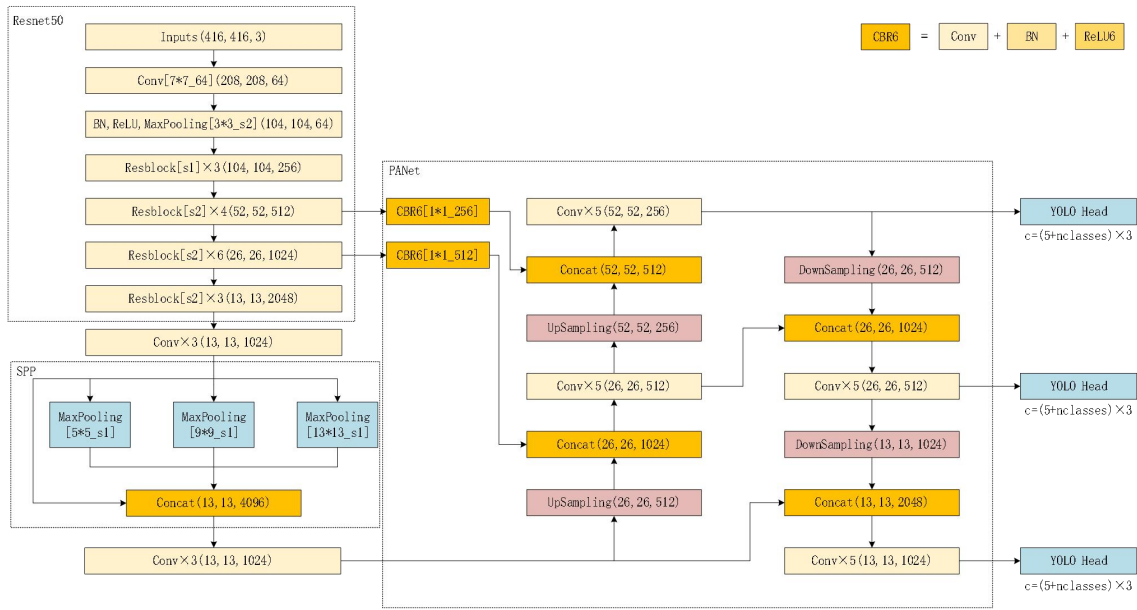


图 3 ResNet50-YOLOv4 整体结构图

Fig.3 Overall structure of ResNet50-YOLOv4

残差网络 ResNet50 使用残差结构 Resblock 为基本结构, 包括残差快和恒等映射结构, 如图 4 所示, 恒等映射允许信息在各特征层之间更容易传播, 这有助于包含位置信息的浅层特征传播, 还使得网络模型更易于训练和优化。

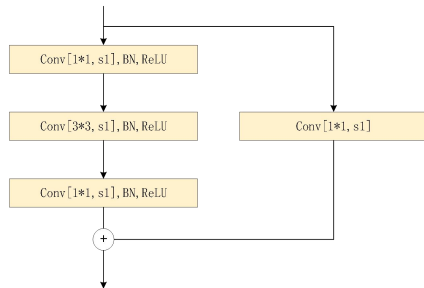


图 4 Resblock 结构图

Fig.4 Resblock structure diagram

考虑到实际的外破隐患目标的尺度在摄像头下的变化, PANet^[19]作为特征融合模块, 其可以在多个尺度下有效地聚合特征。PANet 通过构建自下而上的特征金字塔实现了包含位置信息的浅层特征的有效传播, 并通过自上而下的上采样路径提高了输电线路外力隐患检测的类别判决性能。

1.3 分类损失函数改进

在输电线路外力隐患检测模型的训练阶段, YOLOv4 网络输出多尺度预测结果, 每个尺度预测结果都包含目标的预测信息, 具体指预测结果和真实标签之间的误差损失, 包括位置回归损失、置信度损失和分类损失^[11]。其中目标分类损失采用二元交叉熵损失函数 (Cross-Entropy Loss), 如公式 (1) 所示, 通过计算每一个类别的交叉熵损失, 再对所有类别的交叉熵求和, 用以评估模型的预测性能。

$$L_{cls} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^C y_{ij} \log(p_{ij}) \quad (1)$$

其中, N 表示预测框的数量, C 表示类别数, y_{ij} 表示真实标签, p_{ij} 表示预测概率。

由于输电线路防外破数据集采集于自然场景下的输电杆塔, 其中存在一些噪声和错误的标签, 特别是“施工机械”类别标签易混淆, 包括挖掘机、工程车和其他施工车辆。公式(1)所示的标准交叉熵损失函数在训练时会使模型过度关注训练集上的标签信息, 将标签看作硬指示器函数, 导致模型对于训练数据的过度关注, 对于噪声和错误标签非常敏感容易发生过拟合。

标签平滑技术^[20]通过在训练过程中缓解标签信息的过拟合现象, 通过减少标签的不确定性, 将标签转换为软标签, 减少过拟合。此外, 输电线路外破样本数量较少, 标签平滑可以减轻这种不平衡对模型训练的影响, 提高模型的泛化能力。

本文在标准交叉熵损失函数的基础上, 引入标签平滑技术, 通过对真实标签添加一个惩罚系数, 并添加一个其他标签的偏置项, 改进之后的分类损失函数如下:

$$L_{cls} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^C [(1-\alpha)y_{ij} \log(p_{ij}) + \frac{\alpha}{C} \sum_{k=1}^C y_{ij} \log(\frac{1}{C})] \quad (2)$$

其中, α 表示标签平滑的系数。当 $\alpha = 0$ 时, 事实上就是交叉熵损失函数, 如公式(1)。当 $\alpha > 0$ 时, 会对真实标签进行平滑处理, 给与真实标签不同的其他类别一定概率, 即对真实标签添加一个置信程度。将真实标签从 0 或 1 转换为一个介于 0 和 1 之间的值, 使模型不再过度相信标签, 而是更加相信所学习到的特征信息, 从而降低模型的过于自信, 减少过拟合, 提高模型的鲁棒性。

2. 实验

本文实验仿真采用 Windows 10 操作系统, NVIDIA GeForce RTX 3090 GPU 显卡, 软件为 CUDA11.1, CUDNN8.05, 搭建基于 Pytorch1.7.1 框架的模型训练及测试环境, 以仿真验证本文方法的性能。

2.1 数据分布及超参数设置

本文所建立的输电线路图像数据集, 包含施工机械、吊车、塔吊 3 种外破隐患目标类型, 共计 4083

张。其中包含施工机械类 2001 个, 吊车类 1784 个, 塔吊类 2223 个。将数据集按照 6:2:2 的比例分为训练集、验证集和测试集, 划分结果如表 1 所示。

表 1 数据集划分情况表

类别	训练集	验证集	测试集	合计
施工机械	1201	400	400	2001
塔吊	1333	445	445	2223
吊车	1070	357	357	1784

为了验证本文提出的改进型 YOLOv4 模型性能, 预训练模型的配置文件相关超参数值设置如表 2 所示。

表 2 超参数设置情况

名称	参数
批次大小	24
训练轮次	600
标签平滑系数	0.005
优化器	Adam
学习率	0.001

2.2 评价指标

为了综合验证本文方法的性能, 采用如下四个指标, 分别为精确率(Precision)、召回率(Recall)、F1 值和平均精度值(Mean Average Precision, mAP)。和每秒传输帧数(Frame Per Second, FPS)。

将实际情况的真实类别和模型预测到类别, 分别称为为真正例、假正例、真反例和假反例, 即预测和实际一致则为真, 预测和实际不一致则为假, 如表 3 所示为。

表 3 分类结果组合表

实际情况	预测结果	
	正例(Positive)	反例(Negative)
真例(True)	真正例(TP)	真反例(TN)
假例(False)	假正例(FP)	假反例(FN)

精准率(Precision)表示预测结果为正例样本中真实为正例的比例。精确率高, 意味着分类器要尽量在“更有把握”的情况下才将样本预测为正样本。如式(4)为精准率公式:

$$Precision = \frac{TP}{TP+FP} \quad (4)$$

召回率(Recall)表示正确识别为目标的正样本数与实际目标总数的比例, 如公式(5)所示:

$$Recall = \frac{TP}{TP+FN} \quad (5)$$

F1 值是精确率和召回率的调和平均数,如式(6)所示,

$$F1 = 2 \frac{Precision * Recall}{Precision + Recall} \quad (6)$$

mAP 通过对所有类别的 AP 取平均来计算,如式(7)所示,

$$mAP = \frac{\sum_{i=1}^N AP_i}{N} \quad (7)$$

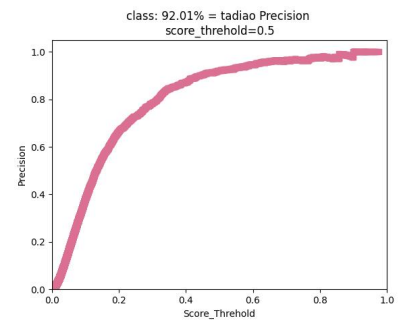
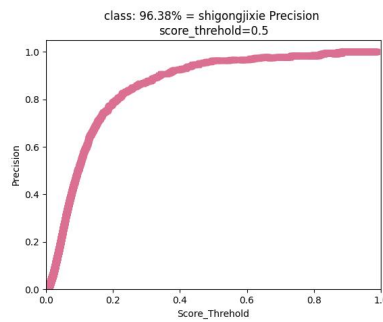
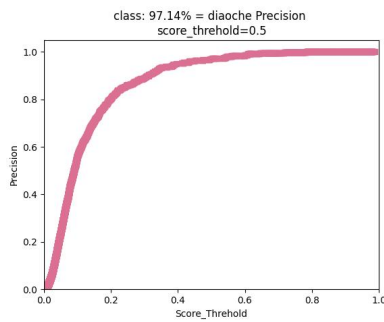
其中, N 表示分类的类别个数, AP_i 表示第 i 个类别的平均精度值。

2.3 实验结果与分析

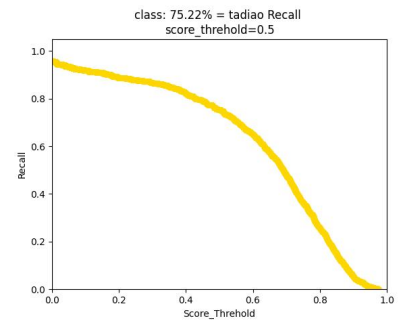
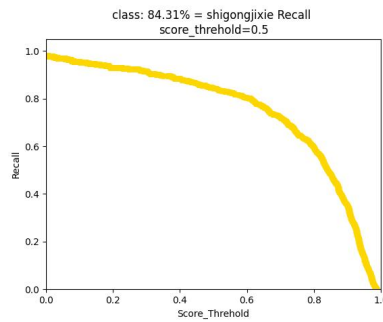
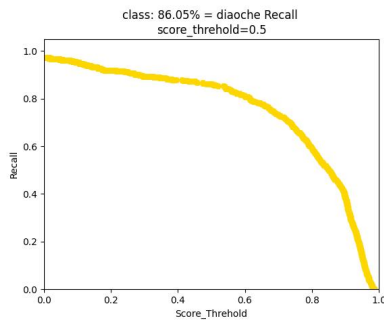
门限值(Threshold score)用于判定真假正反例

概率分数,当概率分数高于该值时,将样本划分为该类别。将测试图片在本文模型上进行测试,得到不同目标的门限值分别对应精准率、召回率和 F1 值的结果如图 5 所示。

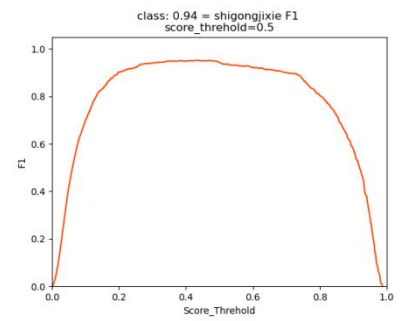

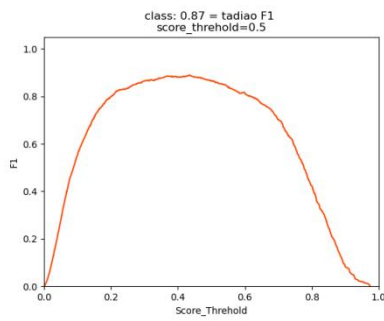
从图 5(a)和(b)可以看出设置过高的门限值,精确率出现上升的趋势,而召回率出现下降的趋势,由于召回率太低意味着模型漏掉了很多真正的目标。而设置过低门限值会出现精确率下降而召回率上升的趋势,这意味着模型将更多的样本预测为正样本,而事实上这些样本并非都是正样本,因此设置过高或过低的二元门限值会使模型对预测样本出现误判的情况,为了权衡精确率和召回率之间的关系,设置合理的门限值非常重要。



(a)门限值与精准率关系图



(b)门限值与召回率关系图



(c)门限值与 F1 值关系图

图 5 门限值关系图

Fig.5 Threshold value relationship diagram

图 5(c)为门限值与 F1 值关系图, F1 是目标检测中精确率和召回率的综合评价指标, 可以看到二者关系呈正态分布状, 因此本文选择门限值为 0.5, 以兼顾精确率和召回率的综合评价因素。

为了验证本文所提出的模型的可行性和鲁棒性, 本文选择不同场景下的图像样本, 用于检测模型在不同背景、姿态、光照、多目标情况下的性能。检测结果如图 6 所示。实验结果表明该模型具有较强的鲁棒性, 能够识别不同光照强度下拍摄的目标图片, 并且能够适应图片的色彩和亮度变化, 这表明该模型具有更广泛的适用性和更强的实用价值。



图 6 模型预测结果图

Fig.6 Prediction result of the proposed model

另外, 本文对所提出的不同标签平滑系数的损失函数进行实验, 在同一训练策略下实验结果如表 5 所示。

表 5 不同标签平滑系数的结果比较

Table 5 Comparison of the results of different label

标签平滑系数	mAP/%
无标签平滑	85.87
$\alpha=0.001$	89.51
$\alpha=0.005$	94.81
$\alpha=0.01$	92.04

从表 5 可以看出, 本文所提出带标签平滑的损失函数比不带标签平滑的效果有显著的提升, 特别是当标签平滑系数为 0.005 时效果最好, mAP 为 94.81%, 最后, 为了证明本文方法的有效性, 在所建立的输电线路防外破数据集上进行对比实验, 采用控制变量的方法对 YOLOv4、Faster R-CNN、SSD 模型进行指标评定。模型对比结果如表 6 所示。

表 6 不同模型对比结果

Table 6 Comparison results of different models

模型	参数量	FPS	mAP/%
YOLOv4	245.5	26.48	94.15
Faster R-CNN	521.6	14	83.33
SSD	91.6	101	81.36
本文算法	128.4	44.82	94.81

从表 6 可以看出, 本文提出的算法比原 YOLOv4 网络模型参数量减少了约 48%, 检测速度较 YOLOv4 提升了约 69%, 而平均精度均值可以达到 94.81%, 高于 YOLOv4; 模型大小较二阶段网络模型 Faster R-CNN 降低了约 75%, 检测速度提升了约 220%; 与 SSD 模型参数量相差不大的情况下, 本文模型精度提升了约 17%。

综合来看, 本文提出的算法在输电线路隐患目标检测任务中表现优异。与其他流行的检测模型相比, 本文算法具有较少的参数量和较高的帧率(FPS), 同时在平均精度(mAP)方面也有着更好的表现。

3.结论

针对目前输电线路防外破检测网络模型难以满足边缘部署对实时性和高精度的应用需求问题, 本文提出了一种融合残差学习的 YOLOv4 并引入标签平滑技术优化损失函数的输电线路防外破隐患检测方法, 得出如下结论:

1) 本文研究建立了输电线路外力隐患图像数据集, 该数据集可用于对基于深度学习的输电线路防外破检测网络模型的训练、验证和测试。

2) 本文提出的融合残差学习的 YOLOv4 输电线路防外破检测网络模型能够实现对输电线路外力隐患类型如施工机械、吊车和塔吊类等检测和识别, 且实时性和检测精度较高。

3) 本文通过实验证明了在输电线路防外力隐患检测方法上, 设置合理的标签平滑系数能够提升检测效果, 对比原始损失函数在检测精度上提升了 8.94%。

4) 与其他同类型目标检测模型相比, 本文所提出的输电线路防外力隐患检测方法在运算速度和检测准确度上均优于其他方法。本文方法的 mAP 分数达到了 94.81%, 高于 YOLOv4、Faster R-CNN 和 SSD 等常见目标检测算法。同时, 本文算法的参数量较小, 可以实现较高的帧率, 实时性较好。

本文所研究的方法适用于输电线路场景下外力隐患类型的检测, 有望为电力行业的自动化管理和智能化监测提供理论和实践支持。后续一方面通过采集和处理更多的输电线路图像, 增加外力隐患的类型, 扩大所建立的输电线路外力隐患图像数据集。另一方面就深入研究并优化输电线路防外破检测网络模型以进一步提高网络模型的性能。

参考文献

- [1] 马新惠, 刘豪, 张世海, 等. 无人机在输电线路巡检中的应用[J]. 机电信息, 2022(8):3.
Ma X H, Liu H, Zhang S H, et al. Application of UAV in Transmission line inspection [J]. Mechanical and Electrical Information, 2022(8):3.
- [2] 吕宁. 基于深度学习的输电线路防外力破坏监测系统研究[D]. 哈尔滨工程大学, 2018.
Lv N. Research on Transmission line Anti-force failure Monitoring System based on Deep Learning [D]. Harbin Engineering University, 2018.
- [3] 张骥, 余娟, 汪金礼, 等. 基于深度学习的输电线路外破图像识别技术[J]. 计算机系统应用, 2018, 27(8): 176-179.
Zhang J, Yu J, Wang J L, et al. Image recognition of power transmission lines broken based on Deep learning [J]. Journal of Computer Systems and Applications, 2018, 27(8): 176-179.
- [4] 赖秋频, 杨军, 谭本东, 等. 基于 YOLOv2 网络的绝缘子自动识别与缺陷诊断模型. 中国电力, 2019, 52(7): 31-39.
Lai Q P, Yang J, Tan B T, et al. Insulator automatic identification and defect diagnosis model based on YOLOv2 network. China Electric Power, 2019, 52(7): 31-39.
- [5] 徐守坤, 倪楚涵, 吉晨晨, 等. 基于 YOLOv3 的施工场景安全帽佩戴的图像描述. 计算机科学, 2020, 47(8): 233-240.
Xu S K, Ni C H, Ji C C, et al. Image description of helmet wearing in construction scene based on YOLOv3. Computer Science, 2020, 47(8): 233-240.
- [6] 孙翠英, 蔡文彪, 贾伯岩, 等. 基于 I-OHEM 的输电线路防外破目标检测方法研究[J]. 电气自动化, 2020, 42(4):4.
Sun C Y, Cai W B, Jia B Y, et al. Research on Detection method of Transmission lines against broken targets based on I-OHEM [J]. Electrical Automation, 2020, 42(4):4.
- [7] 魏贤哲, 卢武, 赵文彬, 等. 基于改进 Mask R-CNN 的输电线路防外破目标检测方法研究[J]. 电力系统保护与控制, 2021, 49(23): 155-162.
Wei X Z, Lu W, Zhao W B, et al. Research on Detection Method of Transmission Lines against Broken Targets Based on Improved Mask R-CNN [J]. Power system Protection and Control, 2021, 49(23): 155-162.
- [8] 缪希仁, 林志成, 江灏, 等. 基于深度卷积神经网络的输电线路防鸟刺部件识别与故障检测[J]. 电网技术, 2021.
Miao X R, Lin Z C, Jiang H, et al. Identification and Fault Detection of Transmission Line anti-bird Prick Components Based on Deep Convolutional Neural Network [J]. Power Grid Technology, 2021.
- [9] 张煜彬, 方中纯. 基于改进 YOLOv3 的输电线路外力破坏危险行为检测[J]. 内蒙古科技大学学报, 2021, 040(004):364-369.
Zhang Y B, Fang Z C. External Damage risk behavior Detection of Transmission Lines based on improved YOLOv3 [J]. Journal of Inner Mongolia University of Science and Technology, 2021, 040(004):364-369.
- [10] 李海峰, 武剑灵, 李立学. YOLOv3-ad 在输电线路监控中提高小目标物体检测准确度的研究[J]. 2021.
Li H F, Wu J L, Li L X. Research on Improving Detection Accuracy of Small Target in Transmission Line Monitoring by YOLOv3-ad [J]. 2021.
- [11] 田二胜, 李春蕾, 朱国栋, 等. 基于 YOLOv4 的输电线路外破隐患识别算法[J]. 计算机系统应用, 2021, 30(7):7.
Tian E S, Li C L, Zhu G D, et al. Outside the transmission line break hazard identification algorithm based on YOLOv4 [J]. Computer system application, 2021, 30 (7):7.
- [12] 唐翔翔, 沈薇, 朱明, 等. 基于改进 YOLOv4 的输电线路异物检测算法[J]. 安徽大学学报:自然科学版, 2021, 45(5):6.
Tang X X, Shen W, Zhu M, et al. Foreign substance detection algorithm for transmission lines based on improved YOLOv4 [J]. Journal of Anhui University: Natural Science, 2021, 45(5):6.
- [13] 丁楠楠, 胡旭晓, 吴跃成, 等. 基于深度学习的输电线路外力破坏检测方法研究[J]. 软件工程, 2022, 25(1):14-17.
Ding N N, Hu X X, Wu Y C et al. Research on External failure detection method of transmission lines based on Deep learning [J]. Software Engineering, 2022, 25(1):14-17.
- [14] Lin T Y, P Dollár, Girshick R, et al. Feature Pyramid Networks for Object Detection[J]. arXiv e-prints, 2016.
- [15] Everingham M, Van Gool L, Williams C K I, et al. The pascal visual object classes (voc) challenge[J]. International journal of computer vision, 2009, 88: 303-308.
- [16] Bochkovskiy A, Wang C Y, Liao H. YOLOv4: Optimal Speed and Accuracy of Object Detection[J]. 2020.
- [17] Wang C Y, Liao H, Wu Y H, et al. CSPNet: A New Backbone that can Enhance Learning Capability of CNN[C]// 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). IEEE, 2020.
- [18] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[J]. IEEE, 2016.
- [19] Liu S, Qi L, Qin H, et al. Path Aggregation Network for Instance Segmentation[J]. IEEE, 2018.
- [20] Szegedy C, Vanhoucke V, Ioffe S, et al. Rethinking the Inception Architecture for Computer Vision[J]. IEEE, 2016:2818-2826.

收稿日期: 2023-03-24.

作者简介:

董卓元(1989-), 男, 硕士研究生, 高级工程师, 研究方向: 输电线路设计相关。

高永亮(1989-), 男, 硕士研究生, 高级工程师, 研究方向: 输电线路设计相关。

袁斌(1964-), 男, 本科, 高级工程师, 研究方向: 输变电工程建设相关。